Maximum K-Cut

Mladen Puzić

4. septembar 2024.

Sadržaj

1 Uvod

Maximum K-Cut problem je klasičan problem optimizacije u teoriji grafova, koji se odnosi na pronalaženje najboljeg načina za podelu skupa čvorova grafa u K disjunktnih podskupova (particija) tako da se maksimizuje težina isečaka (cutova) između različitih podskupova. Isečak između dva podskupa se definiše kao skup grana koje povezuju čvorove iz jednog podskupa sa čvorovima iz drugog podskupa.

1.1 Formalna definicija problema

Dat je graf $G = (V, E)$, gde je V skup čvorova, a E skup grana, pri čemu svaka grana $e \in E$ ima pridruženu težinu $w(e)$. Cilj Maximum K-Cut problema je pronaći particiju skupa V na K podskupova $V_1, V_2, \ldots, V_K$ tako da suma težina grana koje povezuju čvorove iz različitih podskupova bude maksimalna.

1.2 Važnost i primene

Maximum K-Cut problem ima brojne primene u raznim oblastima, uključujući klasterovanje, dizajn mreža, bioinformatiku, mašinsko učenje, kao i u raznim optimizacionim problemima. Na primer, u klasterovanju, ovaj problem može biti korišćen za grupisanje podataka na način koji maksimizuje sličnosti unutar grupa, a minimizuje sličnosti između različitih grupa.

1.3 Kompleksnost

Maximum K-Cut problem je NP-težak, što znači da ne postoji poznat algoritam koji rešava ovaj problem za sve ulazne grafove u polinomijalnom vremenu. Zbog toga se često koriste aproksimativni algoritmi i heuristike za rešavanje ovog problema u praksi.

2 Pristupi rešenju

Za projekat je odabran C++ iz dva razloga, delom zbog svoje efikasnosti, delom zbog potrebe da se projekat koristi i za svrhe predmeta Alati za Razvoj Softvera. Svako rešenje je implementirano kao zasebna klasa, uz nekoliko dodatnih klasa radi lakše organizacije programa. Odabrana rešenja su:

- Gruba sila
- Pohlepni algoritmi (sa prvom promenom, sa najboljom promenom)
- Simulirano kaljenje
- Genetski algoritam

Pogledajmo detaljnije različite aspekte implementacije projekta.

2.1 Predstavljanje grafa

Na slici 1 vidi se implementacija grafa koja se koristi u svim rešenjima. Ona takođe definiše i strukturu grana. U grafu čuvamo broj čvorova i sve grane u vektoru grana. Implementirani su *getteri*, kao i funkcija za dodavanje grana. Broj čvorova se postavlja kroz konstruktor.

```
class Graph {
  public:
   Graph(int nodeCount = 0) {
       m_nodeCount = nodeCount;
   }
   struct Edge {
       int src, dst, w;
   };
   void addEdge(int x, int y, int w);
   int getNodeCount();
   const std::vector<Edge>& getEdges();

  private:
   int m_nodeCount;
   std::vector<Edge> m_edges;
};
```

Slika 1: Definicija grafa

2.2 Predstavljanje rešenja

Klasa *Individual* je dizajnirana za modelovanje jedinke u kontekstu genetskih algoritama, ali je kasnije uopštena za primenu u svim rešenjima, dok je napravljena podklasa za svrhe genetskog algoritma. Klasa omogućava predstavljanje rešenja koje sadrži particiju grafa na određeni broj grupa, kao i procenu kvaliteta te particije kroz funkciju fitnesa.

Za svaki čvor pamtimo kojoj grupi od 0 do $K-1$ pripada. Konstruktor omogućava generisanje nula podele (svi elementi pripadaju grupi 0) ili generisanje nasumične podele. Čuvamo pokazivač na graf, broj grupa i trenutni fitnes. Pruža *getter* za fitness, koji daje i mogućnost da ga izračuna od 0. Fitnes podrazumeva zbir težina grana koje se nalaze između različitih grupa. Ovo se radi u složenosti $O(N)$.

Takođe, pruža mogućnost za sitnu promenu (nasumična promena grupe jednog nasumičnog čvora), koja će se koristiti za simulirano kaljenje. Implementacija se može naći na slici 2.

```
class Individual {
  public:
    Individual() {}
    Individual(Graph *g, int groups, bool rnd)
        : m_fitness(0),
          m_groups(groups),
          m_graph(g),
          m_chooseGroup(std::uniform_int_distribution<int>(a: 0, b: groups - 1)) {
        if (rnd) {
            generateSplit();
        } else {
            m_split = std::vector<int>(n: m_graph->getNodeCount());
        }
    }

    void smallChange();
    long long getFitness(bool recalc = false);
    std::vector<int> m_split;

  protected:
    void generateSplit();
    void updateFitness();

    long long m_fitness;
    int m_groups;
    Graph *m_graph;
    std::uniform_int_distribution<int> m_chooseGroup;
};
```

Slika 2: Predstavljanje rešenja

2.3 Gruba sila

Implementacija brute force algoritma pretražuje sve moguće načine za particionisanje čvorova grafa u grupe. Funkcija run() pokreće pretragu, dok rekurzivna funkcija ispituje svaku moguću particiju. Na kraju, algoritam vraća najbolje rešenje koje je pronašao. Čuvamo trenutno i najbolje rešenje kroz *m_opt* and *m_cur*. Implementacija se može videti na slici 3.

2.4 Pohlepni algoritmi

Implementirane su dve verzije pohlepnog algoritma - po najboljoj promeni i po prvoj boljoj promeni. Oba algoritma pokušavaju da poboljšaju trenutnu particiju grafa tako što premeštaju čvorove između grupa i procenjuju da li to poboljšava fitnes funkciju.

2.4.1 Po najboljoj promeni

- Počinje sa nasumično generisanom particijom grafa.
- Zatim iterativno ispituje sve moguće premene pojedinačnih čvorova u druge grupe kako bi pronašao onu koja donosi najveće poboljšanje u fitnesu.
- Zatim iterativno ispituje sve moguće premene pojedinačnih čvorova u druge grupe kako bi pronašao onu koja donosi najveće poboljšanje u fitnesu.
- Ako se pronađe poboljšanje, primenjuje se najbolja promena i proces se ponavlja dok se više ne može poboljšati rezultat ili dok se ne iscrpe iteracije.

```cpp
class BruteForce {
  public:
   BruteForce(int k = 1, Graph* g = nullptr) {
       m_groups = k;
       m_graph = g;
   }

   long long run();

  private:
   void checkAllOptions(int idx);
   int m_groups;
   Individual m_cur;
   Individual m_opt;
   Graph* m_graph;
};
```

```cpp
void BruteForce::checkAllOptions(int idx) {
    if (idx == m_graph->getNodeCount()) {
        long long curScore = m_cur.getFitness(recalc: true);
        if (curScore > m_opt.getFitness()) {
            m_opt = m_cur;
        }
        return;
    }
    for (int opt = 0; opt < m_groups; opt++) {
        m_cur.m_split[idx] = opt;
        checkAllOptions(idx + 1);
    }
}

long long BruteForce::run() {
    m_cur = Individual(m_graph, m_groups, rnd: false);
    m_opt = m_cur;
    checkAllOptions(idx: 0);
    return m_opt.getFitness();
}
```

Slika 3: Implementacija grube sile

2.4.2 Po prvoj boljoj promeni

- Takođe počinje sa nasumično generisanom particijom grafa.
- U svakom koraku nasumično se određuje redosled čvorova za premenu.
- Algoritam zatim prolazi kroz čvorove i traži prvu promenu koja poboljšava fitnes. Kada je pronađe, odmah je primenjuje i počinje novu iteraciju.
- Proces se nastavlja dokle god se može naći poboljšanje ili dok ne istekne broj iteracija.

Oba algoritma vraćaju konačnu vrednost fitnes funkcije nakon što više nije moguće postići poboljšanje ili nakon što se iscrpe iteracije. Korišćeno je 10000 iteracija. Implementacije se mogu videti na slici 4.

```cpp
long long Greedy::runFirstImprovement(int iter) {
    Individual cur = Individual(m_graph, m_groups, rnd: true);
    long long curFitness = cur.getFitness();
    bool improved = true;
    while (improved && iter--) {
        improved = false;
        auto perm = std::vector<int>(n: m_graph->getNodeCount());
        for (int i = 0; i < perm.size(); i++) {
            perm[i] = i;
        }
        std::shuffle(first: perm.begin(), last: perm.end(), [>>] m_rnd);
        for (auto idx :int : perm) {
            int st = cur.m_split[idx];
            for (int nw = 0; nw < m_groups; nw++) {
                if (st != nw) {
                    cur.m_split[idx] = nw;
                    long long nwFitness = cur.getFitness(recalc: true);
                    if (nwFitness > curFitness) {
                        curFitness = nwFitness;
                        improved = true;
                        break;
                    }
                }
            }
            if (improved) {
                break;
            }
            cur.m_split[idx] = st;
        }
    }
    return cur.getFitness(recalc: true);
}
```

```cpp
long long Greedy::runBestImprovement(int iter) {
    Individual cur = Individual(m_graph, m_groups, rnd: true);
    long long curFitness = cur.getFitness();
    bool improved = true;
    while (improved && iter--) {
        improved = false;
        int mx_idx = 0, mx_grp = cur.m_split[0];
        for (int idx = 0; idx < m_graph->getNodeCount(); idx++) {
            int st = cur.m_split[idx];
            for (int nw = 0; nw < m_groups; nw++) {
                if (st != nw) {
                    cur.m_split[idx] = nw;
                    long long nwFitness = cur.getFitness(recalc: true);
                    if (nwFitness > curFitness) {
                        curFitness = nwFitness;
                        mx_idx = idx;
                        mx_grp = nw;
                    }
                }
            }
            cur.m_split[idx] = st;
        }
        if (cur.m_split[mx_idx] != mx_grp) {
            cur.m_split[mx_idx] = mx_grp;
            improved = true;
        }
    }
    return cur.getFitness(recalc: true);
}
```

Slika 4: Implementacija pohlepnog algoritma

2.5 Simulirano kaljenje

Implementacija simuliranog kaljenja radi tako što kombinuje lokalno pretraživanje sa kontrolisanim slučajnim promenama kako bi se izbeglo zaglavljivanje u lokalnim optimumima. Implementacija se može videti na slici 5.

Neki detalji implementacije:

- Algoritam počinje sa nasumično generisanom particijom grafa (*cur*), koja se takođe postavlja kao trenutno najbolje rešenje (*opt*).
- Tokom zadatog broja iteracija (*iter*), algoritam pravi malu promenu u trenutnom rešenju (*cur*) kako bi dobio novo rešenje (*nw*).
- Ako novo rešenje nije bolje, postoji mala šansa (koja opada tokom iteracija) da će algoritam prihvatiti to lošije rešenje, što omogućava izlazak iz lokalnih optimuma.
- Na kraju, algoritam vraća fitnes najboljeg rešenja (*opt*) koje je pronađeno tokom pretrage.

```
long long SimmulatedAnnealing::run(int iter) {
    Individual cur = Individual(m_graph, m_groups, rnd: true);
    Individual opt = cur;

    for (int idx = 1; idx <= iter; idx++) {
        Individual nw = cur;
        nw.smallChange();
        if (nw.getFitness() > cur.getFitness()) {
            cur = nw;
            if (nw.getFitness() > opt.getFitness()) {
                opt = nw;
            }
        } else {
            int rnd = std::uniform_int_distribution<int>( a: 1,  b: idx)( [&] m_rnd);
            if (rnd == 1) {
                cur = nw;
            }
        }
    }
    return opt.getFitness();
}
```

Slika 5: Implementacija simuliranog kaljenja

Odrađeno je 10000 iteracija.

2.6 Genetski algoritam

2.6.1 GAIndividual

Za svrhe genetskog algoritma napravljena je odvojena podklasa klase *Individual*, *GAIndividual*. Njena definicija se može videti na slici 6.

Dodatno čuva verovatnoću mutacije svakog čvora. Implementira dve funkcije:

- člana *mutate* koji prolazi kroz niz podele i mutira svakog člana (promeni mu grupu) sa verovatnoćom *m_mutationProb*
- statičku funkciju *crossover* koja uzima prvih *position* elemenata iz *a*, a ostatak iz *b*

2.6.2 Selekcija

Na slici 7 se može videti implementacija selekcije:

- Ova funkcija implementira selekciju jedinki iz populacije koristeći pristup turnira.
- Populacija se najpre nasumično promeša.
- Zatim se bira najbolja jedinka iz nasumično odabranog podskupa populacije, koji ima veličinu *tournamentSize*.

```cpp
class GAIndividual : public Individual {
  public:
    GAIndividual(Graph *g, int groups, double mutationProbability = 0.05)
        : Individual(g, groups, true),
          m_mutationProb(mutationProbability),
          m_doesMutate(std::uniform_real_distribution<double>(0, 1)) {}
    static GAIndividual crossover(GAIndividual a, GAIndividual b, int position);
    void mutate();

  private:
    double m_mutationProb;
    std::uniform_real_distribution<double> m_doesMutate;
};
```

Slika 6: Definicija GAIndividual

- Ako se prosledi pokazivač na jedinku koja treba biti isključena (*excl*), ona se neće uzeti u obzir tokom selekcije - radi izbegavanja duplikata.
- Na kraju, funkcija vraća jedinku sa najvišim fitnesom iz tog podskupa kao izabranu jedinku za sledeće korake genetskog algoritma.

Takođe, tu je i implementacija poređenja individua po fitnesu, koja će kasnije biti korisna.

```cpp
bool GeneticAlgorithm::fitnessCmp(GAIndividual a, GAIndividual b) {
    return a.getFitness() > b.getFitness();
}

GAIndividual GeneticAlgorithm::selection(std::vector<GAIndividual> &population,
                                         int tournamentSize,
                                         GAIndividual *excl) {
    std::shuffle(population.begin(), population.end(), m_rnd);
    GAIndividual max_individual = population[0];
    long long max_fitness = -1;
    for (int el = 0; el < tournamentSize; el++) {
        if (&population[el] != excl &&
            population[el].getFitness() > max_fitness) {
            max_fitness = population[el].getFitness();
            max_individual = population[el];
        }
    }
    return max_individual;
}
```

Slika 7: Implementacija selekcije

2.6.3 Implementacija algoritma

Implementacija algoritma se može videti na slici 8.

- Algoritam počinje sa inicijalizacijom populacije od *populationSize* jedinki (*GAIndividual*), gde svaka jedinka predstavlja potencijalno rešenje problema.
- Algoritam zatim prolazi kroz zadati broj generacija (numGenerations), gde se u svakoj generaciji populacija evoluira kroz selekciju, reprodukciju, i mutaciju:
  - Sortiranje - populacija se sortira prema fitnesu korišćenjem funkcije *fitnessCmp*, kako bi jedinke sa boljim fitnesom bile na vrhu.
  - Elitizam - najbolje jedinke iz trenutne populacije (*elitismSize*) se direktno prenose u sledeću generaciju, osiguravajući da se dobra rešenja ne izgube.
  - Selekcija i reprodukcija - za ostatak populacije, jedinke se biraju putem turnirskog izbora (*selection*) kako bi se formirali parovi roditelja. Svaki par roditelja prolazi kroz proces ukrštanja (*crossover*), gde se deliće svojih rešenja kombinuju kako bi formirali dva potomka.

– Mutacija - potomci zatim prolaze kroz proces mutacije (*mutate*), koji uvodi nasumične promene u rešenja sa određenom verovatnoćom (*mutationProb*), čime se omogućava istraživanje novih delova prostora rešenja.

– Ažuriranje populacije - nakon reprodukcije i mutacije, nova generacija zamenjuje staru populaciju.

Na kraju evolucije, algoritam prolazi kroz finalnu populaciju i vraća najviši fitnes pronađen među jedinkama, što predstavlja najbolje rešenje koje je algoritam pronašao.

Ovaj genetski algoritam koristi selekciju na osnovu turnira, elitizam, ukrštanje, i mutaciju kako bi kroz više generacija evoluirao populaciju rešenja i pronašao optimalno ili blizu optimalno rešenje problema particionisanja grafa. Odabrano je koristiti sledeće parametre:

- $populationSize = 200$
- $numGenerations = 100$
- $elitismSize = 20$
- $tournamentSize = 10$
- $mutationProb = 0.1$

```cpp
long long GeneticAlgorithm::run(int populationSize, int numGenerations,
                                int elitismSize, int tournamentSize,
                                double mutationProb) {
    std::vector<GAIndividual> population(
        populationSize, GAIndividual(m_graph, m_groups, mutationProb));
    std::vector<GAIndividual> new_population = population;

    for (int gen = 0; gen < numGenerations; gen++) {
        std::sort(population.begin(), population.end(), fitnessCmp);
        for (int el = 0; el < elitismSize; el++) {
            new_population[el] = population[el];
        }
        for (int j = elitismSize; j < populationSize; j += 2) {
            GAIndividual parent1 = selection(population, tournamentSize);
            GAIndividual parent2 =
                selection(population, tournamentSize, &parent1);

            int randomPos = std::uniform_int_distribution<int>(
                0, m_graph->getNodeCount())(m_rnd);
            new_population[j] =
                GAIndividual::crossover(parent1, parent2, randomPos);
            new_population[j + 1] =
                GAIndividual::crossover(parent2, parent1, randomPos);

            new_population[j].mutate();
            new_population[j + 1].mutate();
        }
        population = new_population;
    }
    long long max_fitness = 0;
    for (auto ind : population) {
        max_fitness = std::max(max_fitness, ind.getFitness());
    }
    return max_fitness;
}
```

Slika 8: Implementacija genetskog algoritma

3 Rezultati

3.1 Testovi

Za svrhe testiranja algoritama generisano je 20 test primera sa različitim svojstvima:

- $1-5$: mali grafovi na kojima se u razumnom vremenu završava brute force, $10 \le n \le 20$, $2 \le k \le 5$.
- $6-10$: grafovi sa većim brojem čvorova, ali malim brojem grana, $120 \le n \le 130$, $190 \le m \le 200$, $2 \le k \le 20$.
- $11-15$: veći, gusti grafovi sa malim brojem grupa, $190 \le n \le 200$, $2 \le k \le 5$.
- $16-20$: veći, gusti grafovi sa većim brojem grupa, $190 \le n \le 200$, $6 \le k \le 20$.

Težine grana su u svim test primerima nasumični brojevi, u prvoj grupi do 100, u ostalim do 10000.

Ovakvim test primerima možemo da ispitamo uspeh algoritama na različitim klasama grafova.

3.2 Rezultati

Na tabeli 1 možemo videti apsolutne vrednosti rezultata svih algoritama na svim primerima. Kao što je očekivano, gruba sila je završila u razumnom vremenu samo na prvih test primera. Iako ne dostižu svi algoritmi vrednosti koje je pronašla gruba sila, možemo primetiti da kombinacijom svih naših optimizacionih metoda dobijamo rešenje koje je optimalno. Što se tiče pojedinačnih algoritama:

- Genetski algoritam pronalazi optimalno rešenje u 3 od 5 testova
- Pohlepni algoritam sa prvom boljom promenom dostiže optimalno rešenje u dva test primera
- Pohlepni algitam sa najboljom promenom ne dostiže maksimum ni u jednom test primeru.
- Simulirano kaljenje dostiže optimalno rešenje u dva test primera.

Odavde možemo videti da se genetski algoritam najbolje snalazio na malim grafovima, dok se pohlepni algoritam sa najboljom promenom snašao ubedljivo najgore.

Test	Genetic Alg	Brute Force	Greedy First	Greedy Best	Simul. Anneal.
1	5414	5414	5208	5159	5366
2	4410	4422	4421	4390	4422
3	2220	2245	2245	2216	2245
4	1781	1781	1781	1775	1767
5	1781	1781	1757	1775	1740
6	998373	DNF	998373	998373	998373
7	998373	DNF	998373	998373	998373
8	998373	DNF	998373	998373	998373
9	998373	DNF	998373	998373	998373
10	998373	DNF	998373	998373	998373
11	64081911	DNF	65742163	65897081	65900744
12	63984576	DNF	65759174	65875541	65592592
13	64001325	DNF	65640470	65930720	65612981
14	63991546	DNF	65768969	65847171	65618374
15	64082178	DNF	65669440	65834406	65844752
16	73863753	DNF	75800299	75904130	75661330
17	73849310	DNF	75816071	75882576	75798196
18	73927324	DNF	75869469	76068139	75849645
19	73738216	DNF	75737432	75886053	75674536
20	73843991	DNF	75942209	75887695	75789954

Tabela 1: Poređenje rezultata algoritama nad test primerima

Možemo pogledati i rešenja prvih 5 primera i grafički na slici 9.

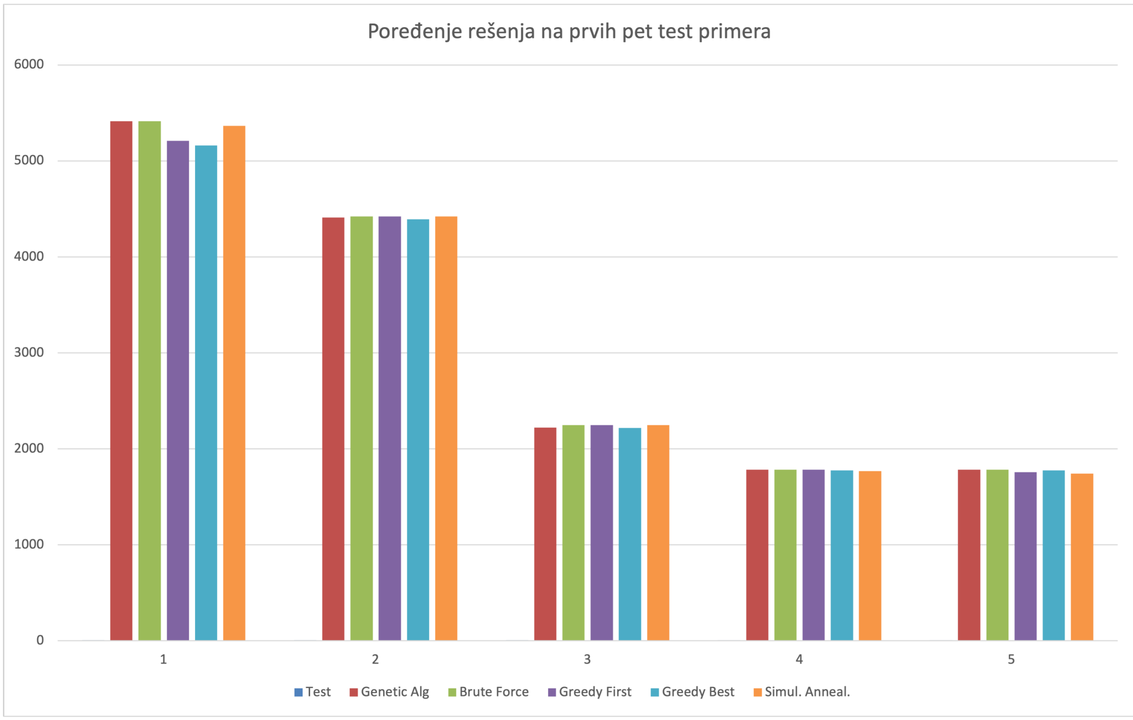

Slika 9: Rešenja na prvih pet test primera

3.3 Poređenje

Pošto je teško porediti apsolutne vrednosti s obzirom na njihovu veličinu, u tabeli 2 se mogu videti vrednosti skalirane tako da najbolja na testu iznosi 1 - odnosno procenat maksimuma koji je pronađen.

Test	Genetic Alg	Brute Force	Greedy First	Greedy Best	Simul. Anneal.
1	1	1	0.961950499	0.952899889	0.991134097
2	0.997286296	1	0.999773858	0.992763455	1
3	0.988864143	1	1	0.987082405	1
4	1	1	1	0.996631106	0.992139248
5	1	1	0.986524424	0.996631106	0.976979225
6	1		1	1	1
7	1		1	1	1
8	1		1	1	1
9	1		1	1	1
10	1		1	1	1
11	0.972400418		0.997593639	0.999944416	1
12	0.971294885		0.998233533	1	0.995704794
13	0.970736024		0.995597652	1	0.995180714
14	0.971819215		0.998812371	1	0.996525333
15	0.973231367		0.997337495	0.999842873	1
16	0.973119025		0.998632077	1	0.996801228
17	0.9732051		0.99912358	1	0.998888019
18	0.971856614		0.997388263	1	0.997127654
19	0.971696551		0.998041524	1	0.997212703
20	0.972370859		1	0.999282165	0.99799512

Tabela 2: Poređenje rezultata kao procenat najboljeg rešenja

Takođe možemo da pogledamo neke grafike, jer je sada lakše primetiti razlike. Pogledati slike 10 i 11.

Na osnovu ovoga možemo da zaključimo dosta korisnih informacija:

- Na prvih pet primera postoji najviše relativne varijacije - ovo ima smisla iz dva razloga - za

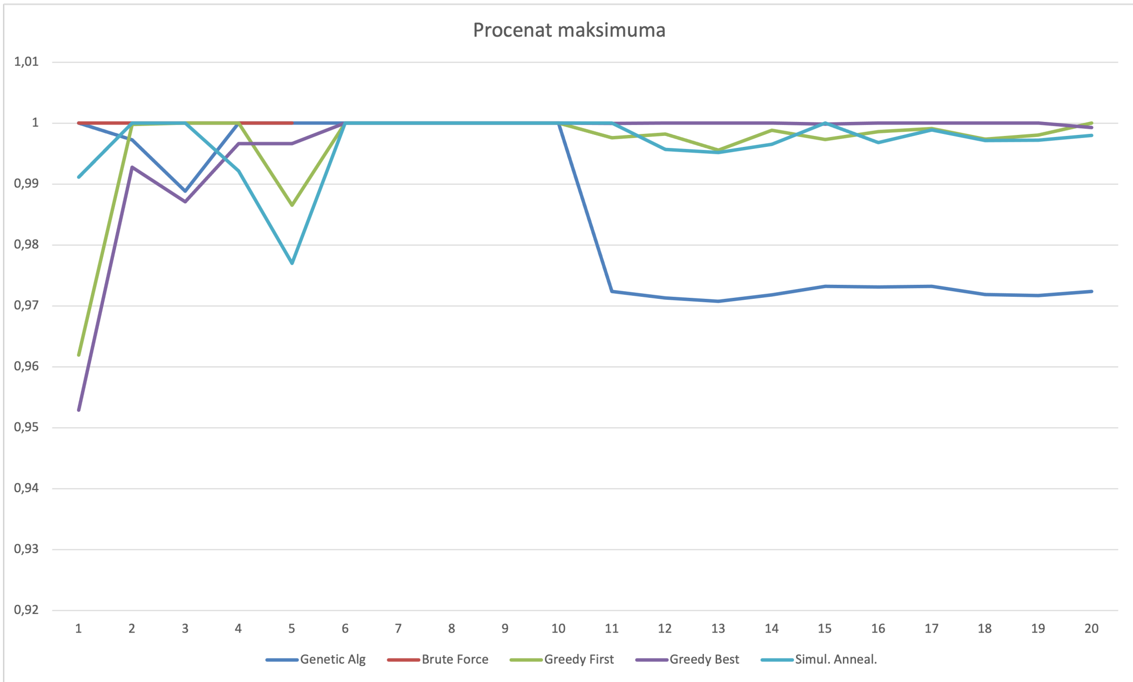

Slika 10: Grafik procenta od maksimuma 1

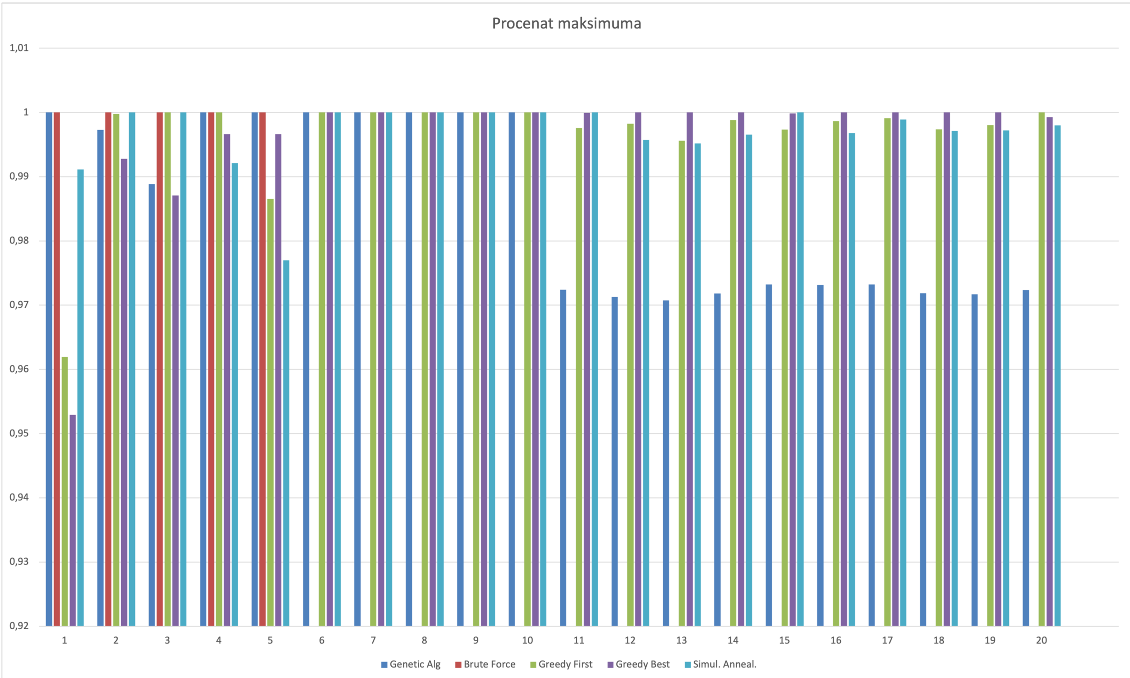

Slika 11: Grafik procenta od maksimuma 2

ovu grupu znamo optimalno rešenje zbog grube sile, tako da se rešenja porede sa optimalnim, takođe apsolutno rešenje je manje, pa manje apsolutne razlike prave veće procentualne razlike.

- Na drugih pet primera svi algoritmi su našli isto rešenje (možemo da pretpostavimo, ali ne možemo dokazati, da je u pitanju maksiumum). Ovo ima smisla, jer manji broj grana dovodi do manje kompleksnosti zadatka.
- Rezultati na poslednjih 10 primera su dosta slični. Vidimo da je na sedam od deset primera najbolji pohlepni algoritam sa najboljom promenom. Simulirano kaljenje i pohledni algoritam sa prvom boljom promene nikad nisu za više od 1% lošiji od maksimuma, dok se genetski pokazao kao najgori sa ispod 97.5% na svakom primeru. Ovo potencijalno naznačava potrebu za različitim parametrima genetskog algoritma u zavisnosti od veličine grafa.

Vidimo zanimljivu činjenicu da su algoritmi koji su bili najbolji na malim grafovima, najgori na velikim, i suprotno. Ovo pokazuje potrebu da uvek imamo više algoritama spremno za kombinovanje kako bismo našli najbolje rešenje što možemo, kao i da budemo svesni tačnih parametara problema koji rešavamo.

4 Zaključak

Maximum K-Cut problem, iako NP-težak, pokazuje različite karakteristike u zavisnosti od veličine i strukture grafa. Na malim grafovima postoji značajna varijacija u rešenjima, pri čemu uspešnost algoritma zavisi od njegove sposobnosti da pronađe konkretno najbolje rešenje. Sa druge strane, kod grafova sa malim brojem grana, svi pristupi obično dovode do istog rešenja, jer su mogućnosti za podelu ograničene.

Na velikim i gustim grafovima, većina algoritama daje rešenja koja se razlikuju za najviše 1%, osim genetskog algoritma, koji zaostaje za oko 3% u odnosu na najbolje rešenje. Ova razlika bi se verovatno mogla smanjiti većim brojem generacija, po ceni vremena izvršavanja. Među ispitivanim algoritmima, pohlepan algoritam sa najboljim promenama se pokazao kao najefikasniji na velikim grafovima, pružajući najbolje rezultate u većini slučajeva.

Za dalje istraživanje bi trebalo uraditi detaljnu analizu razliku pojedinačnih algoritama u zavisnosti od njihovih parametara, kao i dodatni testovi koji podrazumevaju posebne tipove grafova, poput kompletnih, bipartitnih i sličnih grafova. Takođe, različiti parametri algoritama za različite vrste grafova.

5 Literatura

[1] Maximum K-Cut, online at: https://www.csc.kth.se/~viggo/wwwcompendium/node88.html